

夏令营考核题目

课题一：从定义、评测和方法的角度重新审视多模态推理

研究背景

近年来，多模态大语言模型（MLLMs）在视觉问答、图表理解、数学推理、空间推理、科学图理解和视觉规划等任务上取得了显著进展。大量工作将这些能力概括为“多模态推理”或“视觉推理”。然而，当前研究中“多模态推理”这一概念仍缺乏清晰、统一且可操作的定义。许多方法虽然接收图像输入，但其主要推理过程仍发生在语言模态中。在这一范式下，视觉模态更多承担信息输入或证据提供的作用，而未必持续参与推理过程。

因此，当前领域可能混淆了以下三个不同层次：Visual Input（模型是否接收图像输入）、Visual Understanding（模型是否能够识别图像中的对象、属性、关系和结构）、Visual Reasoning（视觉信息是否在推理过程中被持续访问、选择、更新和操作，并对中间推理状态产生实质性影响）。

类似的问题也存在于现有评测体系中。多数多模态推理 benchmark 仅依据最终答案准确率评价模型，但错误答案可能来自多种原因。因此，仅凭最终答案错误，通常无法判断模型是否真正发生了推理失败。

研究目标

本课题聚焦于以图像为主要视觉模态的多模态大语言模型，尝试从定义、评测和方法三个层面重新审视多模态推理，并形成一条完整的研究链路。

RQ1: 如何定义真正的多模态推理？(Definition)

当前大量的多模态推理工作，本质上是基于视觉输入的语言推理，而非视觉与语言共同参与的多模态推理，真正的多模态推理应当允许推理过程动态驱动感知过程。因此我们需要定义一个边界更为清晰的多模态推理。

RQ2: 如何评测多模态推理？(Benchmark)

现有多模态推理 benchmark 通常以最终答案准确率作为唯一指标，因而无法区分推理失败与其他失败模式。一个有效的视觉推理 benchmark 应通过中间过程解耦，将视觉信息获取、证据选择和逻辑推理等过程分别评估。只有当模型在感知正确或感知被人工校正的条件下仍然失败时，才能将错误归因于推理能力不足。

RQ3: 如何建立有效的多模态推理框架？(Method)

当前多模态推理方法存在许多分类（例如基于模型结构改造的方法、基于视觉 token 增强的方法、基于显式 Chain-of-Thought 的方法、基于区域定位或 grounding 的方法、基于工具调用的方法、基于 agent 的多步观察方法、基于程序生成和执行的方法、基于搜索、验证或自我修正的方法）。通过对RQ1和RQ2的研究，我们得到了理想的多模态推理设定和评测基准，下一步就是建立有效的多模态推理框架。

注意：RQ1、RQ2、RQ3的当前设计均为建议，同学可自由探索

考核方式：

1、2、3必做，4可选

1. 总结当前多模态推理方案的特征并根据自己的理解，定义多模态推理
2. 在上述设定的情境下，设计一套评估多模态推理的 benchmark 并进行实验&分析
3. 产出一份报告，包含多模态推理设定+benchmark设计+实验&分析
4. 提出一个自己的多模态推理方法，可以没有实验，但要有合理假设和总体框架设计

课题二：基于无障碍电影特性先验的免训练多智能体旁白生成

研究背景：

当前，在无障碍电影旁白（AD）自动化生成的探索中，学术界正面临着底层基础大模型（Base Model）演进带来的双重困境。

首先，传统的端到端微调（Fine-tuning）路线正遭遇严峻的生态与数据瓶颈。随着顶尖多模态基础模型逐渐向闭源 API 演进，研究者越来越难以对底层网络进行深层参数更新。更重要的是，高质量、符合专业播音标准的 AD 数据在现实中极度匮乏且标注成本极高。这导致强行微调不仅算力开销巨大，还极易在小样本上发生过拟合，难以泛化至复杂的未见电影场景。

其次，为规避训练成本而转向基于闭源 API 的免训练（Training-Free）架构同样面临硬伤。通用大模型的预训练语料多源自互联网的松散描述，在执行严格的 AD 任务时会产生严重的“幻觉（Hallucinations）”。它们极易脱离视觉事实生造画面细节，或主观揣测角色的内心动机，直接违背了 AD 创作不可逾越的“客观唯物原则”。

因此，破局的核心已不再是堆叠算力或粗暴的提示词拼接，而是回归电影本身。通过挖掘并利用 AD 领域的固有特性，将长视频底层逻辑高度结构化，构建免训练的多智能体系统。

研究目标:

本研究围绕免训练多智能体无障碍电影旁白生成展开，目标包括：

1. 深入剖析现有前沿AD模型的幻觉现象与成因机制。针对现有大模型在执行严格AD任务时生造视觉细节和主观揣测等痛点，全面调研AutoAD系列等现有工作。通过建立bad case分析报告，明确免训练架构在无障碍旁白生成中的事实性缺陷及其触发机制。
2. 构建具备高度结构化视频逻辑的免训练多智能体系统。依托Qwen3-VL或Qwen3.6系列底层大模型，深度融合无障碍播音的“客观唯物原则”。通过 Harness Engineering 划分专职 Agent，以协同工作机制有效抑制模型幻觉，实现高质量旁白生成。
3. 在标准数据集上完成系统性的效果评估与基准对比。在 MAD-eval-Named、CMD-AD 或 TV-AD 等主流无障碍旁白基准数据集上抽取测试子集，对所构建的 MAS 进行定性与定量评估，验证其在幻觉消除、事实准确度及文本质量上相较于现有Baseline模型的优势与有效性。
4. 开发端到端的无障碍电影旁白智能生成交互平台。设计并实现一个易用且完整的工程化闭环 Demo（包含前后端系统）。支持用户上传视频片段，系统即可通过调动MAS 进行自动分析并输出匹配画面的AD文本，验证该架构的落地应用潜力。

考核方式:

1. 关于现有的AD模型出现幻觉的情况调研总结，分析现有的model output里面出现的幻觉bad case分析报告
2. 基于Qwen3-VL或者qwen3.6系列搭建MAS，思考如何设计agent可以缓解幻觉
3. 该agent在MAD-eval-Named或者CMD-AD或者TV-AD上随机抽取子集进行测试，与现有其他baseline对比
4. MAS构造简单前后端交互系统，上传视频片段，智能生成旁白的demo
5. 完整代码和实验报告，MAS架构图

参考资料:

模型:

AutoAD I: Movie Description in Context

AutoAD II: The Sequel - Who, When, and What in Movie Audio Description

AutoAD III: The Prequel -- Back to the Pixels（提供了model output）

AutoAD-Zero: A Training-Free Framework for Zero-Shot Audio Description（提供了model output）

Shot-by-Shot: Film-Grammar-Aware Training-Free Audio Description Generation
(training-free & 提供了model output)

DistinctAD: Distinctive Audio Description Generation in Contexts

Contextual AD Narration with Interleaved Multimodal Sequence

benchmark:

MAD-eval-Named: <https://github.com/TengdaHan/AutoAD>

CMD-AD: <https://www.robots.ox.ac.uk/~vgg/research/autoad/index.html>

TV-AD: <https://github.com/Jyxarthur/AutoAD-Zero>

What You See is What You Ask: Evaluating Audio Descriptions

课题三：MLLM驱动的 Mobile-use Agent 的记忆管理研究

一、研究背景

随着多模态大语言模型（Multimodal Large Language Models, MLLMs）的快速发展，模型已逐步具备屏幕内容理解、GUI元素定位、工具调用与任务规划等 Agentic 能力，并在长程推理与复杂任务执行中展现出显著潜力。基于 MLLM 构建能够像人类一样操作智能手机的 Mobile-use Agent，被认为是通往通用人工智能的重要技术路径之一。其核心目标是通过设计具备感知、决策和执行能力的智能体系统，使模型能够在真实或仿真的手机环境中完成任务自动化，例如跨应用的信息检索、内容填写、设置修改与事务处理等。

在 Mobile-use Agent 的实现过程中，GUI Agent 是关键技术模块。该类方法通常基于预定义动作空间（如点击、滑动、输入、返回等），结合当前屏幕截图和任务指令，直接预测下一步操作，从而驱动智能体与移动端图形界面交互。尽管现有端到端单智能体 GUI Agent 在短流程任务上已取得一定效果，但在处理长程推理任务时仍存在明显局限，尤其是在以下场景中表现不足：

1. 跨应用任务链条较长：任务往往涉及多个 App、多个页面跳转及 20 步以上交互；
2. 历史行为难以有效保留：智能体难以稳定记住“已完成了什么、当前处于什么状态、后续应如何规划”；
3. 长期依赖利用不足：缺乏对关键中间信息、页面状态变化和历史决策线索的持续建模，导致重复操作、错误回退或任务中断。

因此，针对 Mobile-use Agent 在长程任务中的“记忆短板”问题，本研究拟构建融合记忆机制的多智能体框架，通过引入显式记忆管理与多角色协作机制，增强智能体对历史行为、环境状态和任务上下文的追踪能力，从而提升其在复杂长程任务上的稳定性与成功率。

二、研究目标

本研究围绕 MLLM 驱动的 Mobile-use Agent 的记忆管理问题 展开，目标包括：

1. 梳理 GUI Agent 场景下记忆机制的研究现状，总结现有方法在长期任务执行中的优势与不足；
2. 基于 Qwen3-VL-32B-Instruct 构建端到端 GUI Agent baseline，在 AndroidWorld Benchmark 上评测其在 Hard task 上的表现；
3. 设计融合记忆机制的多智能体框架，重点探索任务历史管理、状态摘要、经验复用与多轮规划能力；
4. 系统验证记忆机制对长程任务性能的提升效果，通过成功率、性能增幅及案例分析评估方法有效性；
5. 完成代码、实验报告与系统框架文档的整理与提交，形成可复现的研究成果。

三、研究内容与技术路线

本研究将从以下几个方面展开：

1. GUI Agent 记忆机制调研

围绕 GUI Agent、Mobile-use Agent 和 MLLM Agent 领域，对当前与记忆相关的研究进行系统调研，重点关注以下问题：

- 单智能体端到端 GUI Agent 的执行范式及其局限；
- 多智能体框架在复杂 GUI 任务中的应用方式；
- 记忆表示形式，如轨迹缓存、结构化状态、知识图、层次化记忆、自演化记忆等；
- 记忆模块在任务规划、错误恢复、长期依赖建模中的具体作用。

调研结果将整理为研究综述报告，为后续方法设计提供依据。

2. 端到端 GUI Agent baseline 搭建

基于 Qwen3-VL-32B-Instruct，按照 AndroidWorld Benchmark 的环境配置要求，搭建一个端到端 GUI Agent。该 baseline 以当前页面观察和任务目标为输入，直接输出动作决策，在 Hard task 上进行测试，并记录成功率作为对比基线。

3. 面向长程任务的多智能体记忆框架设计

在 baseline 基础上，进一步设计融合记忆机制的多智能体系统。初步设想包括：

- 规划智能体（Planner）：负责根据任务目标和当前状态生成阶段性子目标；
- 执行智能体（Executor）：负责具体的 GUI 操作执行；
- 记忆智能体（Memory Manager）：负责存储、更新和检索历史信息，如已完成步骤、关键页面状态、失败经验和重要中间变量；
- 反思/校验智能体（Reflector/Critic）：在必要时对当前动作、历史轨迹与任务进度进行一致性检查，辅助纠错与重规划。

记忆机制的研究重点包括：

- 如何表示操作历史与页面状态；
- 如何从长轨迹中筛选关键信息，避免上下文冗余；
- 如何在决策时高效检索与当前任务相关的历史记忆；
- 如何通过结构化记忆或知识图提升跨页面、跨 App 的长期依赖建模能力。

4. Benchmark 评测与实验分析

在 AndroidWorld Benchmark 上对所设计方法进行系统评测，重点关注 Hard task，并在时间允许的情况下扩展至 Medium task。通过定量与定性结合的方式，比较 baseline 与引入记忆机制后的性能差异，分析方法在不同类型长程任务中的表现特点。

四、考核方式

1. 调研与报告

调研 GUI Agent 场景下与记忆机制相关的研究现状，完成一份综述分析报告，内容包括：

- 相关工作分类；
- 各类记忆机制的核心思想；
- 现有方法的优缺点；
- 本研究的切入点与创新空间。

2. AndroidWorld Benchmark 部署与实验

完成 AndroidWorld Benchmark 环境部署，重点测试 Hard task，具体包括：

2.1 Baseline 构建与评测

使用 Qwen3-VL-32B-Instruct 搭建端到端 GUI Agent，在 Hard task 上完成测试，记录成功率，作为 baseline。

2.2 多智能体记忆框架构建与评测

使用 Qwen3-VL-32B-Instruct 设计并实现融合记忆机制的多智能体框架，在 Hard task 上完成测试，记录：

- 任务成功率；
- 相比 baseline 的提升百分比；
- 典型成功/失败案例分析。

2.3 扩展实验（可选）

若时间允许，可进一步在 Medium task 上进行补充实验，以验证方法的泛化性与稳定性。

3. 代码整理与提交

整理实验代码、运行脚本、配置说明与关键模块实现，确保研究过程具有可复现性。

4. 实验报告与方法文档

撰写并提交完整实验报告，内容包括：

- 方法设计思路；
- 系统框架图与模块说明；
- 工作流程描述；
- 实验设置与评测结果；
- 样例分析与误差分析；
- 总结与未来改进方向。

五、预期成果

本研究预期形成以下成果：

1. 一份关于 GUI Agent 记忆机制的调研报告；
2. 一个基于 Qwen3-VL-32B-Instruct 的端到端 GUI Agent baseline；
3. 一个面向长程任务的、融合记忆机制的多智能体 Mobile-use Agent 原型系统；

4. 在 AndroidWorld Benchmark 上的实验结果与性能对比分析；
5. 完整的代码、实验报告、框架图和方法文档。

六、参考资料

1. AndroidWorld

- Github 仓库: https://github.com/google-research/android_world
- Paper: <https://arxiv.org/abs/2405.14573>

2. Qwen3-VL

- Prompt 使用方法: https://github.com/QwenLM/Qwen3-VL/blob/main/cookbooks/mobile_agent.ipynb
- Paper: <https://arxiv.org/pdf/2511.21631>

3. 参考文献

- SeeClick: <https://arxiv.org/pdf/2401.10935>
- HAR-GUI: <https://arxiv.org/abs/2511.09127>
(参考其 Github 中的 prompt 设计, 理解 End-to-End GUI Agent 的执行逻辑)
- LAMO: <https://arxiv.org/abs/2604.13488>
(参考其多智能体框架与 prompt 设计, 理解多智能体执行逻辑)
- MobileAgent-V3: <https://arxiv.org/pdf/2508.15144>
(参考其多智能体框架设计思路)
- PG-Agent: <https://arxiv.org/pdf/2509.03536>
(参考其基于知识图的记忆管理方式)
- HYMEM: <https://arxiv.org/pdf/2603.10291>
(参考其自进化 memory 设计思路)
- Agent-S2: <https://arxiv.org/pdf/2504.00906>
(参考其多智能体框架设计思路)