

SUMMER CAMP • FINAL REPORT

GUI Agent 长程任务中的 记忆机制探索

从多维实验比较，到可审计的信息谱系分析

浙江大学夏令营课题最终汇报

汇报人：_____ · 2026.08.19

RESEARCH QUESTION

研究问题逐步收敛：记忆是否有用，取决于信息如何影响决策

01

先让失败可信

复现基线，冻结配置，排除基础设施与人为错误。

02

横向比较机制

复刻文献思想，也设计多种最小记忆与负对照。

03

纵向追求提升

从 A1 到 R2，先保护已有能力，再争取新增成功。

04

重新定义问题

R15 单题成功与 4/7 补测共同限定：先找断点，再选干预。

贯穿全程的判断标准：最终分数、运行代价、机制激活、行为分叉与因果归因必须分开报告。

第一项成果不是一个新模块，而是一套可信的实验基础

57 / 57

三 seed 全部科学有效

0

动作执行失败

19

AndroidWorld Hard 任务

32B

Qwen3-VL 模型

每条轨迹保留完整证据链

截图 / UI 状态

Thought / Action

memory write / read / 注入

执行动作 / evaluator

- **系统结果**：是否成功，调用、token 与耗时多少
- **机制激活**：记忆是否真的写入并进入模型请求
- **因果归因**：相关读取是否先于有益动作分叉

“代码接上了” “记忆被读取了” “成功由记忆造成” 是三个不同命题。

基线既有明显 seed 波动，也证明“忘记”不是失败的统一解释

同一 19 题集的完整成功数

**7 / 57**

完整成功


21

虚假成功声明

39

重复状态

开发 seed 的最早可证失败层



因此研究问题不是“加不加记忆”，而是记忆能否保存任务相关绑定，并在正确决策点发挥作用。

EXPERIMENT DESIGN

两条实验轴覆盖“记什么”与“怎样提升”，五个维度共同裁决

横向 | 文献启发

A3 • 经验记忆

A4 • 工作流记忆

A5 • 分层记忆

横向 | 自主设计

A6 • 转移回放

A7 • 透明控制

A8-A12 • 恢复/义务/前沿

纵向 | 能力提升

A0 • 4/19

→

A1 • 5/19

→

A2 • 0/19

→

R2 • 6/19

→

R3-R14 gates

→

R15 • 4/7 诊断

结果

成功与逐题得失

代价

调用、token、耗时

激活

写入、读取、注入

因果

信息保真与行为分叉

同一实验在不同维度上可能得到相反判断，不能只看最终分数。

MULTI-DIMENSIONAL COMPARISON

同一组实验换五个比较维度，结论不再是简单的“有效或无效”

方法	完整结果	总 token	机制激活	行为 / 因果	综合裁决
A0	4/19	1.273M	无显式记忆	行为基线	开发 seed 参照
A1	5/19	3.464M	515 writes / 580 reads	相对 A0: 1 胜、0 负	有正信号，但代价高
A2	0/19	3.170M	656/705 调用读到记忆	0 新增、丢失 A1 全部 5 题	强反例：激活不等于收益
R2	6/19	2.686M	六个成功均有非空读取	相对 A1: 1 胜、0 负	系统结果最强；因果待消融
A6	0/19	—	625 actions；持续回放活跃	读取后重复与低变化动作增加	信息过量会稳定错误
R15	4/7*	0.586M / 六题	六题全部 0 activation/read	相对 R2 六题: 0 胜、3 平、3 负	产生诊断线索，未形成通用升级

* 旧 Browser 成功与后续六题拼接的描述性诊断面板；不是完整 19 题结果，也不是匹配消融。

最重要的实验结论：分数、成本、激活率和因果证据必须同时比较，单一维度会误导设计。

MAIN SYSTEM RESULT

R2 是目前最扎实的完整结果：能力提升、零退化、成本下降

COMPACT VERIFIED + PENDING MEMORY

6 / 19

保留 A1 的五个成功任务
新增 **OsmAndMarker**

逐题配对：1 胜 · 0 负 · 18 平

-22.5%

相对 A1 的总 token

-23.1%

相对 A1 的有效耗时

603

模型调用，与 A1 持平

6.5

总奖励，高于 A1 的 5.5

设计变化：把记忆压缩成“已验证事实 + 未完成事项”，避免与历史重复。

边界：非空读取证明机制活跃；缺少匹配的 read-disabled 消融，不能把全部收益强归因于记忆。

R2 回答了“怎样在不破坏已有能力的前提下改进系统”，但尚未回答“收益究竟由哪段信息造成”。

WHAT THE NEGATIVE RESULTS TAUGHT US

大量零分并非白跑，它们分别排除了四种看似合理的设计路径

失败类型	已有数据	真正得到的设计结论
论文思想的最小移植	A3: 12/34 合规写入; A4: 错误 donor 注入 34/34 步; A5: 0/34 合规写入	最小外挂不能替代 donor、匹配、训练、检索与完整系统
更多记忆与回放	A6 为 0/19, 625 actions 中重复与低变化行为增多	信息量增加可能稳定错误策略，而非提升能力
读到了就能恢复	A8–A12 的读取集中在失败题; A10-v2 有 6 次读取但 0 个 有益分叉	读取必须相关、及时，并真正改变下一动作
连续针对首题打补丁	R3–R12 是十次独立 0/1 gate; 后版本继承全部旧补丁	串行堆栈与单轨迹过拟合破坏可归因性

旧流程：失败症状 → 增加字段、规则或提示。

新需求：先定位跨轨迹的共同断点，再设计单一变量。

大量实验已经审计“记忆写入以后”；R15 进一步说明，“写入以前”的信息变换也必须进入证据链。

THE R15 TURNING POINT

R15 提供关键正例，但七题补测只得到 4/7

四条轨迹都看到: $1 \times 8 \times 10 \times 7 \times 2$

R2

120

R13D

720

R14

2310

R15

1120

R15 的原始 Thought / Action 历史逐步保留了五个值，最终计算正确并通过 evaluator。

4 / 7

固定诊断面板

0 / 6

补跑六题机制激活

作用域检验: Browser 暴露了历史变换中的信息损失；另外六题没有同类值流，三项回归则来自导航、恢复与完成验证。

R15 不是更强的通用系统；它的价值是产生一个可审计解释，并由 4/7 补测明确限定这个解释能够覆盖什么。

把任务相关事实作为审计单位，才能定位最早的信息断点



新的分析单位

不再问“组件运行了吗”，而问一个关键事实在哪一层丢失。

新的因果判据

相关读取必须先于动作分叉，并产生可见进展。

新的数据价值

失败轨迹也能区分感知、变换、写入、检索和使用错误。

由数据产生的可检验假设：相较于“记忆是否激活”，任务事实抵达哪一层、又在哪一层丢失，可能更能解释最终成败。

WHAT 4/7 ACTUALLY TELLS US

三项回归表明：长程失败不只有“忘记”这一种来源

0 / 6

机制激活 / 读取

3 平 · 3 负

相对 R2 六题的描述性对照

+180,350

额外 token

任务	最早可见问题	失败链	对应干预
Calendar	路由与预算管理	无效首步后逐日导航，34 步耗尽仍未保存	路线级恢复与预算感知
Recipe	识别与无进展恢复	未识别并打开 Broccoli，重复滚动后主动失败	状态变化检测与重定位
OsmAnd	完成证据不足	把 Add / favorite 误当 Marker，错误宣告完成	结果前证据核验

4/7 不支持把 Browser 的单题解释外推为通用提升；它进一步要求先定位最早断点，再决定改记忆、恢复策略还是完成验证。

COMPARISON OF ANALYSIS UNITS

代表工作多比较系统增益；我们追踪事实在哪一层失效

代表性工作主要比较什么

AWM	归纳并调用成功工作流，比较系统任务表现
HyMEM / MemGUI-Agent	设计结构化或混合记忆，以组件消融检验总体增益
MemGUI-Bench	构造记忆密集任务，以任务与分层指标衡量能力
ATMem	配对 memory-ON/OFF rollout，估计策略层的记忆贡献

OUR ADDITIONAL ANALYSIS SCALE

从系统级比较下沉到事实级归因

- 单位：完成任务所需的最小事实
- 链路：原始表述 → 历史变换 → 写入 → 读取 → 动作
- 判据：相关读取 → 有益分叉 → evaluator 结果
- 结果：同为零分，也能定位不同的最早断点

相关工作：Agent Workflow Memory；HyMEM；MemGUI-Agent；MemGUI-Bench；ATMem。对照的是主要实验与归因尺度，不否定各论文内部分析。

系统级增益回答“是否有效”；事实级谱系补充解释“为什么在这里有效或失效”，并直接指出下一次干预应发生在哪一层。

CONCLUSION

一个月的工作最终形成：一个结果、一组边界、一个问题

01

可信实验资产

57 条三 seed 基线、完整轨迹、失败分层与严格评测边界。

02

系统与经验结论

R2 达到 6/19 且降低成本；多类负结果界定何种记忆不会有效。

03

可检验问题

R15 的 1/1 线索与 4/7 边界共同提出：最早信息断点能否更好指导干预？

下一步验证：分别对选择性信息保真、无进展恢复和完成证据检查做匹配消融，再扩展到多 seed、多模型。

最终回答：记忆的价值不在“存得更多”，而在正确证据能够穿过整条信息链，并在正确决策点产生可验证的有益分叉。

TAKE-HOME MESSAGE

从“记忆是否运行”到“信息为何有效”

最有价值的结果不是 4/7，而是知道下一次实验应该改变哪一层。



谢谢 · Questions & Discussion