

SUMMER CAMP • FINAL REPORT

GUI Agent 长程任务中的 记忆：从系统增益到信息归因

一条配对系统进展，以及一次由反例推动的分析尺度转折

浙江大学夏令营课题最终汇报

汇报人：_____ · 2026.08.19

RESEARCH QUESTION

记忆何时才有资格获得“有用”的信用？

A1

5 / 19

出现一个新增成功，
但调用、token 与错误循环显著增加

≠

A2

656 / 705

多数调用读到记忆，
最终却是 0 / 19

≠

R2

6 / 19

完整系统结果更好，
但缺少 matched read-disabled 消融

研究问题


什么信息、在什么任务上、通过哪一阶段，才会产生可验证的有益动作分叉？

active ≠ useful; success ≠ causal credit. 最终分数、机制激活和因果归因必须分开。

EVIDENCE SCALE

三 seed 基线先告诉我们：单个分数不是稳定能力，也不是机制因果

同一 19 题集，完整成功数仍明显波动



7 / 57 完整成功 **57 / 57** 科学有效 episode

系统比较强度

单例 — 子集 — 逐题配对 — 多 seed

任务、seed、模型、controller 与运行条件是否可比？

机制归因强度

共现 — 读取 — 动作分叉 — 匹配反事实

信息是否进入请求、先于相关动作，并产生 evaluator 进展？

R2：系统比较较强，组件因果仍弱。

R15 Browser：单轨迹观察很强，跨 arm 因果比较仍弱。

A0 的 4/2/1 是后续所有单 seed 结果的“证据校准器”，不是可以忽略的附属数字。

THE FIRST CONTRADICTION

A1 → A2: 记忆越活跃，结果反而可能越差



A1 给出正信号，也暴露代价

- 相对 A0: 1 胜、0 负、18 平
- 一个 Recipe 轨迹支持 persistent pending 的候选价值
- 但 token、耗时与长循环同步增加

A2 是“高激活、零收益”的强反例

- 丢失 A1 的全部五个成功任务
- 单条最近进度难以表达集合与跨页面路线
- “更可信、更频繁”不是单调改进轴

问题从“有没有记忆”转为：失败发生在没写入、内容不相关、读后不分叉，还是任务本就不是记忆瓶颈？

WHAT THE NEGATIVE RESULTS ACTUALLY MEAN

A3-A12 不是失败方法目录，而是不同信息断点的探针

代表实验	机会	激活 / 写入	相关性	读取	有益分叉	结果与证据功能
A5 分层/图记忆	●	0/34	-	-	-	未激活：不能评价后续检索价值
A4 工作流记忆	△	●	add → delete	34/34	0	内容不相关：donor 匹配先于 read count
A8 复访恢复	●	●	△	14	0	有读无恢复：提醒重复不等于替代动作
A6 持续转移回放	●	过度	△	持续	错误稳定	过度活跃：重复与低变化动作增加
A7 / A9 透明 / 稀疏控制	△	△	△	△	无新增证据	静默成功：成功共现不能给组件记功
A10-A12 精细触发	部分	部分	更严格	失败题	0	仍停在 L5：精细触发不自动产生行动

● 直接观察到 ● 部分/不充分 ● 明确断点

相同的 0 分，对应完全不同的下一步干预。

这些结果约束的是“简单外挂实现”，不是对 AWM、HyMEM 或 MemGUI-Agent 完整系统的否定。

MAIN SYSTEM RESULT

R2 是目前最可靠的完整系统进展，但不是机制因果终点

COMPACT VERIFIED + PENDING

6 / 19

相对 A1: 1 胜 • 0 负 • 18 平

保留 A1 五个成功，并新增 OsmAndMarker

-22.5%

总 token

-23.1%

有效耗时

603 = 603

模型调用与 A1 持平

必须同时讲清的边界

固定单 seed 配对；严格 cost gate 因 calls 未下降而 **FAIL**；没有 matched read-disabled 消融。

允许结论：R2 系统身份在该 seed 上更好、更省 token/time；禁止结论：稳定泛化或某段记忆文本已被证明致因。

SYSTEM RESULT $\neq$ COMPONENT CAUSALITY

R2 的关键缺口：6/6 成功有 read，仍不构成因果

已经建立

配对系统结果**1w / 0l / 18t**

同一固定 19 题上保留五项能力、增加一项能力，
token/time 更低。

缺少反事实

同一状态
read-enabled vs read-disabled
或内容删除

尚未建立

组件因果信用**6 / 6 reads**


读取与成功只是共现；必须观察相关信息是否先于有益
动作分叉。

只有“相关信息进入请求 → 动作发生相关分叉 → evaluator 出现进展 → 匹配反事实成立”，才能授予强因果信用。

主动暴露最佳结果的归因边界，不会削弱成果；它恰恰说明后续实验该补什么证据。

THE R15 TURNING POINT

Browser 成功了，但新组件没有读：归因单位必须下沉到任务事实



事实

普通 Thought/Action 历史逐步保留五值并算对；
成熟 EVR read = 0。

允许解释

只从 writer/read 开始审计不足；上游保真与答案合成都需要被观测。

待验证假设

在累积事实任务中，保留任务相关原始事实会提高正确动作概率。

R15 Browser 是“成功但组件无信用”的直接反例；它改变的是审计顺序，不是最佳方法排名。

WHAT 4/7 ACTUALLY MEANS

R15 的 4/7 是诊断组合，不是可以进入排行榜的方法分数

Browser 成功 普通历史五值链 EVR read = 0	Expense 成功 组件静默	Retro 成功 组件静默	Sports 成功 组件静默	Calendar 回归 零机会	Recipe 回归 零机会	OsmAnd 回归 零机会
3 / 6 continuation	0 六题 opportunity / activation / read / use			0w · 3t · 3r 相对历史 R2，非匹配		+180,350 额外 token

可以排除： EVR 内容直接毒化三项回归，因为它从未进入请求。 **不能排除：** 起始状态、路线、temperature、长轨迹与其他 run-identity 差异。

一个无组件读取的正例、三个静默成功、三个零机会回归：4/7 把“得分”拆成作用域、激活与归因。

MATCH THE INTERVENTION TO THE BOTTLENECK

同是长程失败，四类任务需要的干预并不相同

代表任务	任务所需信息	最早/主要瓶颈	更匹配的最小干预
Browser 累积数值	五个值、完整乘积、提交前核验	事实保真 + 答案合成	exact-prefix 三臂事实保留反事实
Calendar 添加事件	日期定位、跳转路线、剩余预算	路由 / 预算	路线恢复 + budget-aware jump
Recipe 约束删除	目标识别、滚动后的状态变化	识别 / 无进展恢复	object checklist + re-localization
OsmAnd 添加 Marker	控件语义、页面转移、完成证据	grounding / 完成验证	transition verification + evidence gate

干预选择规则：先定位任务所需最小事实的最早断点，再决定使用记忆、路由恢复、状态重定位还是完成核验。

“长程任务失败”不是一个可操作的机制目标；“某类任务事实在某一阶段失去可用性”才是。

从组件审计到事实级归因：追踪信息在哪一层首次失去可用性



opportunity → activation → append → read / use → action divergence → evaluator progress

A5
L3 未写入

A4
L4 前相关性失败

A8-A12
有读无 L5

R15 六题
opportunity = 0

Browser
成功但 EVR 静默

数据驱动、待验证的框架：任一前置环节为 0，就不给组件记功；链条闭合后，强因果仍需 matched counterfactual。

它不是“更强记忆算法”，而是一套把负结果转化为下一次可证伪实验的诊断尺度。

COMPLEMENTARY ANALYSIS SCALES

与相关工作的差异不在“谁更强”，而在研究对象与归因单位

工作	主要研究对象	主要分析单位 / 归因尺度	本项目不能据此声称什么
AWM	成功样例归纳与检索 workflow	workflow / task / 系统消融	A4 donor 错配不能评价完整 AWM
HyMEM	结构化图与连续轨迹记忆	graph / retrieval / 组件与系统	A5 未复刻学习表示与完整系统
MemGUI-Agent	主动上下文管理策略	context action / 训练后 policy	A3 零样本字段不是完整复现
MemGUI-Bench	memory-centric GUI 评测	task / challenge / 分层指标	本项目尚不是通用 benchmark
ATMem	task-driving state 与配对 rollout	policy / memory-ON-OFF 贡献	本项目尚缺同等强度 matched intervention
本项目	冻结轨迹中最小任务事实的可用性	fact × stage × trajectory: L0-L6	当前是诊断框架，不是已验证的通用方法

Sources: AWM (arXiv:2409.07429); HyMEM (Findings of ACL 2026); MemGUI-Agent (arXiv:2606.19926); MemGUI-Bench (arXiv:2602.06075); ATMem (arXiv:2606.31612).

本项目补充的是事实级断点诊断；只有 matched intervention 能把这一尺度从解释框架推进到稳健因果结论。

CONCLUSION

一个系统结果，一组证据边界，一个可检验框架

01 系统结果 R2 在固定单 seed 的完整 19 题上达到 6/19，相对 A1 为 1w/0l/18t，并降低 token/time。

02 证据边界 激活、读取、动作分叉与成功不能混为一谈；R15 的 4/7 进一步限制了单题解释的作用域。

03 分析框架 下一步以任务所需最小事实为单位追踪 L0-L6，并用 matched 反事实授予机制信用。

哪条任务事实，在哪一层失去可用性，什么干预能让它产生有益动作分叉？

Questions & Discussion