

SUMMER CAMP • FINAL REPORT

GUI Agent 长程任务中的 记忆：从系统增益到信息归因

从显式任务账本的纵向改进，到事实级因果归因的分析转折

浙江大学夏令营课题最终汇报

汇报人：许奕 · 2026.08.19

一个总分无法同时回答“系统是否更好”和“为什么更好”

问题 A

完整系统是否进步？

固定任务、seed、模型与 controller，逐题比较成功、成本和能力保留。

证据：matched suite / multi-seed

≠

问题 B

进步为什么发生？

相关信息是否有机会进入请求、改变动作，并在匹配反事实下产生进展。

证据：fact lineage / action divergence

核心问题

怎样设计记忆使系统进步，又怎样证明这份进步真正来自记忆？

后续所有实验都分别回答这两个问题：系统结果与机制信用不能互相替代。

THE AUDITABLE BASELINE

A0 先建立可信起点：无显式任务账本，三 seed 为 4 / 2 / 1

同一 19 题集，完整成功数仍明显波动

20260806		4 / 19
20260807		2 / 19
20260808		1 / 19

7 / 57 完整成功 **57 / 57** 科学有效 episode

A0 输入与行为

当前截图 + 普通 Thought / Action 历史

- 没有跨步显式的 verified / pending 任务账本
- 动作执行、奖励和 step 轨迹均可审计
- 基础设施错误不进入科学结果

比较规则：后续单 seed 只支持同 seed 配对结论；单个高分不能代表稳定能力。

A0 不只是一个分数，而是后续每次改动的可比起点和证据校准器。

THE MAIN VERTICAL LINE

A0 → A1 → R2: 先让待办持续可见，再只保留真正有用的最小账本

A0 • 无显式任务状态

截图 + 普通历史

假设起点：长程任务中的未确认事项可能随历史增长而失去显著性。

4 / 19

开发 seed

A1 • Action Working Memory

最多六条 observed / verified / pending

理论：持续提醒已完成与未确认事项，避免最后一步被遗忘。

5 / 19

新增 Recipe; calls +83%, tokens +172%

R2 • Compact Verified / Pending

只留最新账本，删除 observed 与历史重复

理论：当前截图是权威；保留有效待办，同时减少陈旧状态和上下文负担。

6 / 19

保留五题 + Osm; token / time 下降

真正的设计演进：不是“记忆越多越好”，而是从无账本，到显式待办，再到选择性最小账本。

纵向结果支持一个系统设计方向：保留任务义务，但让当前视觉状态压过陈旧的自述历史。

WHY TARGETED UPGRADES DID NOT BECOME WINS

“没有新增成功” 可能发生在四个不同环节，不能直接判定诊断错误

实验方向	想解决什么	操纵检查	结果	真正能得出的结论
A2 可信进度	减少随口生成与错误状态	高读取	0 / 19	更可信、更频繁的单条进度并非充分条件
A3 / A5 字段 / 图记忆	更结构化地保存上下文	不完整 / 未激活	0 / 1	否定的是最小移植可行性，不是完整论文方法
A4 工作流检索	复用成功 workflow	donor 错配	0 / 1	相关性在读取之前已失败，不能评价 AWM 本体
A6 持续轨迹回放	减少历史遗忘	过度活跃	0 / 19	更多历史会与重复动作、错误策略稳定同时出现
A8-A12 恢复与精细触发	检测停滞并提醒恢复	有读 / 有触发	0 个有益分叉	发现症状不等于模型获得可执行的替代策略
R3-R12 纵向补丁链	修复 R2 后的单条失败	串行叠加	10 × 0 / 1	回归基线上连续打补丁，未形成干净的 R2 单变量检验

判别顺序：先确认机制有机会并真正改变目标变量，再看动作是否分叉；只有局部瓶颈被修复仍无进展，才能说它不是充分原因。

负结果没有被“圆掉”：它们分别否定实现、相关性、充分性或研发路径，而不是统一否定记忆方向。

MAIN SYSTEM RESULT

R2 是目前最可靠的完整系统进展，但不是机制因果终点

COMPACT VERIFIED + PENDING

6 / 19

相对 A1: 1 胜 • 0 负 • 18 平

保留 A1 五个成功，并新增 OsmAndMarker

-22.5%

总 token

-23.1%

有效耗时

603 = 603

模型调用与 A1 持平

必须同时讲清的边界

固定单 seed 配对；严格 cost gate 因 calls 未下降而 **FAIL**；没有 matched read-disabled 消融。

允许结论：R2 系统身份在该 seed 上更好、更省 token/time；禁止结论：稳定泛化或某段记忆文本已被证明致因。

WHY THE BEST SYSTEM STILL FAILS

R2 的 13 个失败不是同一种记忆问题，统一补丁自然难以奏效

7 / 13

耗尽步数，长期未解决

失败组平均 38.31 actions; MarkorMerge 与 OsmAndTrack 合计贡献 94 / 130 次 same-state refresh。

需要：路线恢复、多对象 frontier、可执行替代策略

6 / 13

主动给出错误完成判断

3 个错误 terminate(success), 3 个错误 answer; 不是增加 pending 文本就能解决。

需要：对象核验、答案检查、completion grounding

未真正检验

R3、A5 未激活; P2/P3 未通过预检; R15 六题零机会。

检验后否定充分性

A8、R9、A10-A12 有触发或读取，但没有有益动作分叉。

局部改善仍不足


R11 改善一次删除; R12 降低重复成本，完整任务仍有其他瓶颈。

R2 的边界：它优化的是任务状态表示，不增加感知、规划、恢复或完成验证; 6 / 6 成功有 read 仍缺 matched read-disabled 消融。

“观察到重复”可以是真的，但“重复是唯一根因、文字提醒足以解决”可以同时是错的。

THE R15 TURNING POINT

Browser 成功了，但新组件没有读：归因单位必须下沉到任务事实



事实

普通 Thought/Action 历史逐步保留五值并算对；
R15 特有组件 read = 0。

允许解释

只从 writer/read 开始审计不足；上游保真与答案合成都需要被观测。

待验证假设

在累积事实任务中，保留任务相关原始事实会提高正确动作概率。

R15 Browser 是“成功但组件无信用”的直接反例；它改变的是审计顺序，不是最佳方法排名。

WHAT 4/7 ACTUALLY MEANS

R15 的 4/7 是诊断组合，不是可以进入排行榜的方法分数

Browser 成功 普通历史五值链 新增组件 read = 0	Expense 成功 组件静默	Retro 成功 组件静默	Sports 成功 组件静默	Calendar 回归 零机会	Recipe 回归 零机会	OsmAnd 回归 零机会
3 / 6 continuation	0 六题 opportunity / activation / read / use			0w · 3t · 3r 相对历史 R2，非匹配		+180,350 额外 token

可以排除：新增记忆内容直接毒化三项回归，因为它从未进入请求。 **不能排除：**起始状态、路线、temperature、长轨迹与其他 run-identity 差异。

一个无组件读取的正例、三个静默成功、三个零机会回归：4/7 把“得分”拆成作用域、激活与归因。

R2 与 R15 共同推动新顺序：先追踪任务事实，再评价记忆组件



框架的价值不是给失败重新命名，而是决定下一次该操纵哪一层、用什么局部指标验证。

COMPLEMENTARY ANALYSIS SCALES

不宣称“比论文更强”：本项目补充的是更细的事实级归因单位

工作	主要研究对象	主要分析单位 / 归因尺度	本项目不能据此声称什么
AWM	成功样例归纳与检索 workflow	workflow / task / 系统消融	A4 donor 错配不能评价完整 AWM
HyMEM	结构化图与连续轨迹记忆	graph / retrieval / 组件与系统	A5 未复刻学习表示与完整系统
MemGUI-Agent	主动上下文管理策略	context action / 训练后 policy	A3 零样本字段不是完整复现
MemGUI-Bench	memory-centric GUI 评测	task / challenge / 分层指标	本项目尚不是通用 benchmark
ATMem	task-driving state 与配对 rollout	policy / memory-ON-OFF 贡献	本项目尚缺同等强度 matched intervention
本项目	冻结轨迹中最小任务事实的可用性	fact × stage × trajectory: L0-L6	当前是诊断框架，不是已验证的通用方法

Sources: AWM (arXiv:2409.07429); HyMEM (Findings of ACL 2026); MemGUI-Agent (arXiv:2606.19926); MemGUI-Bench (arXiv:2602.06075); ATMem (arXiv:2606.31612).

本项目补充的是事实级断点诊断；只有 matched intervention 能把这一尺度从解释框架推进到稳健因果结论。

三条结论分别需要三种证据，下一步不再继续堆通用记忆字段

当前结论	已经建立的证据	仍不能声称	信息增益最大的验证
R2 是系统进展	完整 19 题；对 A1 为 1w / 0l / 18t; token / time 更低	稳定泛化、组件因果	A1 / R2 多 seed; R2 matched read / content ablation
失败瓶颈异质	7 题耗尽预算; 6 题错误完成或答案; 不同激活断点	所有失败都是记忆问题	按任务族冻结事实、动作分叉和局部 progress 指标
L0-L6 可组织诊断	A5 未写入、A4 错配、有读无分叉、silent success 等反例	已验证的新算法或普遍定律	Browser exact-prefix 三臂反事实 + 一项瓶颈匹配在线干预

最小决定性实验：冻结 Browser 同一截图、prompt 与 decoding，对比原历史、真实五值、等长无关数值，观察正确 1120 与首个动作分叉。

下一步的目标不是“再做一个模块”，而是用最小反事实区分事实保真、一般上下文和随机推理。

CONCLUSION

一条系统演进，一组异质失败，一个可检验框架

- 01 纵向结果** A0 无显式账本，A1 给出 pending 的正信号但成本较高，R2 以最小 verified / pending 保留五题并新增一题。
- 02 失败解释** R2 的 13 个失败分为长期未解决与错误完成判断；后续负结果分别否定实现、相关性或充分性。
- 03 分析框架** R15 促使审计从组件下沉到任务事实；下一步用 L0-L6 与 matched 反事实选择瓶颈匹配干预。

不是“记忆越多越好”，而是哪条事实、在哪一层、通过什么干预真正改变了动作。

Questions & Discussion