

SUMMER CAMP • FINAL REPORT

GUI Agent 长程任务中的 记忆：从系统增益到信息归因

从显式任务账本的纵向改进，到事实级因果归因的分析转折

浙江大学夏令营课题最终汇报

汇报人：许奕 · 2026.08.19

一个总分无法同时回答“系统是否更好”和“为什么更好”

问题 A

完整系统是否进步？

固定任务、seed、模型与 controller，逐题比较成功、成本和能力保留。

证据：matched suite / multi-seed

≠

问题 B

进步为什么发生？

相关信息是否有机会进入请求、改变动作，并在匹配反事实下产生进展。

证据：fact lineage / action divergence

核心问题

怎样设计记忆使系统进步，又怎样证明这份进步真正来自记忆？

后续所有实验都分别回答这两个问题：系统结果与机制信用不能互相替代。

THE AUDITABLE BASELINE

A0 先建立可信起点：无显式任务账本，三 seed 为 4 / 2 / 1

同一 19 题集，完整成功数仍明显波动

20260806		4 / 19
20260807		2 / 19
20260808		1 / 19

7 / 57 完整成功 **57 / 57** 科学有效 episode

A0 输入与行为

当前截图 + 普通 Thought / Action 历史

- 没有跨步显式的 verified / pending 任务账本
- 动作执行、奖励和 step 轨迹均可审计
- 基础设施错误不进入科学结果

比较规则：后续单 seed 只支持同 seed 配对结论；单个高分不能代表稳定能力。

A0 不只是一个分数，而是后续每次改动的可比起点和证据校准器。

THE MAIN VERTICAL LINE

A0 → A1 → R2: 先让待办持续可见，再只保留真正有用的最小账本

A0 • 无显式任务状态

截图 + 普通历史

假设起点：长程任务中的未确认事项可能随历史增长而失去显著性。

4 / 19

开发 seed

A1 • Action Working Memory

最多六条 observed / verified / pending

理论：持续提醒已完成与未确认事项，避免最后一步被遗忘。

5 / 19

新增 Recipe; calls +83%, tokens +172%

R2 • Compact Verified / Pending

只留最新账本，删除 observed 与历史重复

理论：当前截图是权威；保留有效待办，同时减少陈旧状态和上下文负担。

6 / 19

保留五题 + Osm; token / time 下降

真正的设计演进：不是“记忆越多越好”，而是从无账本，到显式待办，再到选择性最小账本。

纵向结果支持一个系统设计方向：保留任务义务，但让当前视觉状态压过陈旧的自述历史。

WHY TARGETED UPGRADES DID NOT BECOME WINS

“没有新增成功” 可能发生在四个不同环节，不能直接判定诊断错误

实验方向	想解决什么	操纵检查	结果	真正能得出的结论
A2 可信进度	减少随口生成与错误状态	高读取	0 / 19	更可信、更频繁的单条进度并非充分条件
A3 / A5 字段 / 图记忆	更结构化地保存上下文	不完整 / 未激活	0 / 1	否定的是最小移植可行性，不是完整论文方法
A4 工作流检索	复用成功 workflow	donor 错配	0 / 1	相关性在读取之前已失败，不能评价 AWM 本体
A6 持续轨迹回放	减少历史遗忘	过度活跃	0 / 19	更多历史会与重复动作、错误策略稳定同时出现
A8-A12 恢复与精细触发	检测停滞并提醒恢复	有读 / 有触发	0 个有益分叉	发现症状不等于模型获得可执行的替代策略
R3-R12 纵向补丁链	修复 R2 后的单条失败	串行叠加	10 × 0 / 1	回归基线上连续打补丁，未形成干净的 R2 单变量检验

判别顺序：先确认机制有机会并真正改变目标变量，再看动作是否分叉；只有局部瓶颈被修复仍无进展，才能说它不是充分原因。

负结果没有被“圆掉”：它们分别否定实现、相关性、充分性或研发路径，而不是统一否定记忆方向。

MAIN SYSTEM RESULT

R2 用最小任务账本做到 6 / 19：系统增益与低复杂度同时成立

COMPACT VERIFIED + PENDING

6 / 19


31.6% · AndroidWorld Hard

相对 A1: 1 胜 · 0 负 · 18 平

-22.5%
token-23.1%
time0
额外模型调用

NUMERICAL CONTEXT, NOT A LEADERBOARD

同一官方 Hard 难度划分的数值坐标



复杂度证据

R2: 单执行器 + 账本

MobileUse: Operator + Progressor + 三级 Reflector

Sources: MobileUse, NeurIPS 2025, Table 4; official AndroidWorld task list. 不同 backbone、run、seed 与版本, 仅作数值和复杂度语境。

可守住的亮点：在混合能力的 19 个 Hard 任务上，轻量记忆干预达到 MobileUse 最强 Hard 消融的同一数值，同时不引入规划器、验证器或反思器调用。

THE SAME ZERO CAN CONTAIN DIFFERENT EVIDENCE


终分都为 0，但轨迹已经告诉我们：修复发生在不同层，剩余瓶颈也不同

升级链	仅看终分	轨迹中的真实变化	机会链断点	为什么仍未成功
R5 → R6 目标保持	0 → 0	原始目标重新进入上下文，goal 丢失被修复	L2-L4 已修	错误空间点击与弱恢复仍在 L5-L6
R7 → R9 循环恢复	0 → 0	R9 检测器实际触发 3 次	到达 L4	提醒未产生有效动作分叉，停在 L5
R10 → R11 对象核验	0 → 0	一次错误删除被纠正	局部 L5-L6	完整任务仍含其他对象与完成验证瓶颈
R11 → R12 去重压缩	0 → 0	去除 174 条重复记录，token -4.37%	成本侧改善	降低冗余不等于获得新的解题策略
已建立 描述性映射		有证据 回顾性断点区分		尚未建立 前瞻预测有效性

这不是事后为失败改名：它解释了“按旧诊断为何应升级、按断点诊断为何仍不会过关”，并把下一次干预从继续堆字段改为修复最早断点。

THE R15 TURNING POINT

Browser 成功了，但新组件没有读：归因单位必须下沉到任务事实



事实

普通 Thought/Action 历史逐步保留五值并算对；
R15 特有组件 read = 0。

允许解释

只从 writer/read 开始审计不足；上游保真与答案合成都需要被观测。

待验证假设

在累积事实任务中，保留任务相关原始事实会提高正确动作概率。

R15 Browser 是“成功但组件无信用”的直接反例；它改变的是审计顺序，不是最佳方法排名。

WHAT 4/7 ACTUALLY MEANS

R15 的 4/7 是诊断组合，不是可以进入排行榜的方法分数

Browser 成功 普通历史五值链 新增组件 read = 0	Expense 成功 组件静默	Retro 成功 组件静默	Sports 成功 组件静默	Calendar 回归 零机会	Recipe 回归 零机会	OsmAnd 回归 零机会
3 / 6 continuation	0 六题 opportunity / activation / read / use			0w · 3t · 3r 相对历史 R2，非匹配		+180,350 额外 token

可以排除：新增记忆内容直接毒化三项回归，因为它从未进入请求。 **不能排除：**起始状态、路线、temperature、长轨迹与其他 run-identity 差异。

一个无组件读取的正例、三个静默成功、三个零机会回归：4/7 把“得分”拆成作用域、激活与归因。

WHY 6 / 19 IS A MEANINGFUL SYSTEM RESULT

这 19 题不是“纯记忆小测”：R2 在混合能力 Hard 集上保留并扩展成功

OFFICIAL ANDROIDWORLD HARD TASK CLASSES

官方标签覆盖至少 10 类需求

memorization

multi-app

screen reading

data entry

transcription

complex UI

search

repetition

math / counting

information retrieval

因此主结果始终使用完整 19 题分母，不从标签中事后挑选一个更好看的“记忆子集”。

R2 SUCCESS COVERAGE • 6 TASKS

多对象 / 约束 ExpenseDeleteMultiple2 · RecipeDeleteConstraint

长流程状态 RetroSavePlaylist · CalendarAddEvent

聚合 / 核验 SportsTotalDuration · OsmAndMarker

31.6% 轻量记忆干预在混合 Hard 能力上的系统表现

Source: official AndroidWorld task list. 标签描述任务需求，不等价于对失败根因的机制标注。

R2 的价值不是“解决了所有记忆题”，而是在不增加复合能力模块的前提下，让一个最小任务账本对多种长程任务形态都没有造成能力回归。

COMPLEMENTARY ANALYSIS SCALES

论文多在任务、故障类型或模块层分析；我们把信用继续下沉到单条事实的最早断点

MOBILEUSE • NEURIPS 2025

系统组件与分层反思

按 error type 分析，并消融 Action / Trajectory / Global Reflector 与 Progressor。

单位：任务 / 故障类型 / 模块

MEMGUI-BENCH • 2026

记忆保持率与五类失败

用 IRR、memory-unit 指标和 failure modes 专门衡量 GUI Agent 记忆。

单位：任务 / challenge / memory unit

本项目 • FROZEN TRACE AUDIT

事实 × 阶段 × 轨迹

定位最早断点，再检查 opportunity、read、action divergence 与 progress。

单位：单条事实的因果信用链

互补而非替代

宽尺度告诉我们“哪类系统容易失败”

→ 细尺度告诉我们“下一次应操纵哪一层”

Sources: MobileUse, NeurIPS 2025; MemGUI-Bench, arXiv:2602.06075. 不声称事实级分析普遍首次出现。

潜在新意不在于再发明一个字段，而在于把轨迹审计变成可反驳的 credit-assignment：只有通过匹配反事实，组件才能获得因果信用。

它已经能解释旧实验为何失败；能否前瞻指导新设计，仍需决定性检验



01 描述性映射

已在 A / R 系列轨迹中建立

02 回顾性区分

能区分未激活、错配、有读无分叉、局部改善

03 前瞻预测

尚未证明能稳定选出更优干预

两步验证

盲法双人标注最早断点 + 一致性

→ 预注册的瓶颈匹配干预 vs 等长无关信息

当前贡献是有证据支持的回顾性诊断框架；下一步若能预测哪种最小干预有效，才升级为经过验证的设计方法。

CONCLUSION

轻量系统增益，异质失败证据，可检验的分析转折

- 01 系统结果** R2 以最小 verified / pending 账本达到 6 / 19，在混合 Hard 任务上取得 31.6%，且零额外模型调用。
- 02 实验结论** 横向说明纯记忆并非普适解；纵向说明记忆不是越多越好，选择性保留比持续堆叠更有效。
- 03 分析转折** R15 促使审计从组件下沉到任务事实；旧实验已支持回顾性断点诊断，前瞻预测仍待匹配反事实验证。

不是“记忆越多越好”，而是哪条事实、在哪一层、通过什么干预真正改变了动作。

Questions & Discussion